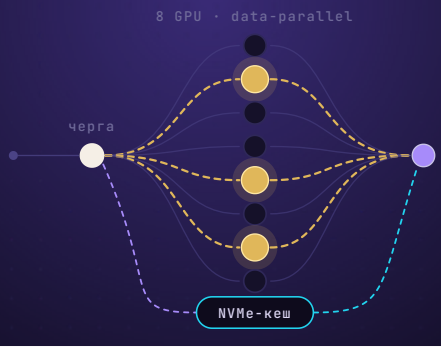
UKRLAW · ТЕСТОВЕ ЗАВДАННЯ · AI INFRASTRUCTURE ENGINEER

Локальна AI-інфраструктура для генерації відео

Сервер на 8 GPU, локальні моделі, вебінтерфейс і API з чергою завдань. Від збірки до production.

8 × RTX PRO 6000 · 768 ГБ VRAM · PRODUCTION ЗА 10 ТИЖНІВ



Технічне рішення для UKRLAW · Богдан Гаврилюк · 26.10.2026 · ціни й версії станом на цю дату · PDF, 5 сторінок

Коротко

Що	Рішення
Сервер	1 вузол 4U: 8 × NVIDIA RTX PRO 6000 Blackwell Max-Q (768 ГБ VRAM), 2 × AMD EPYC 9355, 512 ГБ DDR5, 7.7 ТБ NVMe
Продуктивність	≈ 20–30 кліпів 720p × 5 с на годину на GPU (Wan 2.2 + 4-step LoRA): 100–150 на пулі hq (5 GPU), до 160–240 на всіх восьми. Оцінка від виміряних 656 с на кліп при 20 кроках (600-ватна версія)
Бюджет	CAPEX ≈ $194 тис. ($170–220 тис.), OPEX ≈ $1.6 тис./міс. Варіанти: $140 тис. (RTX PRO 5000) і 4 + 4 GPU ($130 + $64 тис.)
Моделі	Wan 2.2 (основна), LTX-2.5 (звук, чернетки), Qwen-Image і Z-Image (кадри), SeedVR2 (апскейл), Qwen3 (промпти, модерація)
Платформа	Web Studio, REST API, черга на PostgreSQL, ComfyUI-воркер на кожен GPU, моніторинг DCGM + Prometheus
Запуск	10 тижнів до production, якщо GPU є на складі. Перші 2 тижні: пілот на орендованих GPU
Висновок	Власний сервер дешевший за оренду за завантаження понад 50–70%. До цього: пілот на оренді й закупівля 4 + 4 GPU

Відповідність вимогам ТЗ

Вимога ТЗ	Де	Вимога ТЗ	Де
Сервер, компоненти, бюджет	1.1	Linux, драйвер, CUDA, PyTorch, Docker	2.2
Обґрунтування GPU, VRAM, CPU, PCIe, RAM, дисків, живлення, охолодження	1.2, 1.3	Вебінтерфейс, API, черга	2.3
Multi-GPU і масштабування	1.4	Етапи запуску до production	3.1
AI-моделі для відео	2.1	Моніторинг GPU, стабільності, продуктивності	3.2
Ризики й способи усунення	3.3	Посилання на попередні проєкти	Досвід

1. Архітектура інфраструктури

1.1 Специфікація і бюджет

№	Компонент	Модель / специфікація	Шт.	$/шт.	Разом, $
1	GPU	NVIDIA RTX PRO 6000 Blackwell Max-Q, 96 ГБ GDDR7 ECC, 300 Вт	8	16 000	128 000
2	Сервер	Supermicro AS-4125GS-TNRT: 4U, плата H13DSG-O-CPU rev. 2.x, 4 × 2000 Вт Titanium, 8 вентиляторів	1	9 000	9 000
3	CPU	AMD EPYC 9355: 32 ядра, 3.55–4.4 ГГц, 280 Вт	2	3 700	7 400
4	RAM	DDR5 ECC RDIMM 64 ГБ (DDR5-6000+), по 4 модулі на сокет	8	2 400	19 200
5	NVMe	3.84 ТБ U.2, ≥ 1 DWPD (Samsung PM9A3, Micron 7500 PRO або Kioxia CM7-R) ‡	4	1 600	6 400
6	SATA	480 ГБ enterprise SSD (Micron 5400 PRO або Samsung PM893) ‡	2	250	500
7	Живлення	ДБЖ online 10 кВА, 230 В, і 2 × PDU 32 А (власна серверна) ‡	1	9 000	9 000
8	Стійка	42U, рейки, кабелі (власна серверна) ‡	1	2 000	2 000
9	Підтримка	3 роки NBD на сервер і ЗІП (БЖ, вентилятори, DIMM) ‡			12 000
	Разом				**193 500**

Ціни без ПДВ на 26.10.2026. Ринкові: GPU $15 999.99 (Central Computer), EPYC 9355 $3 694 (прайс AMD), 64 ГБ DDR5 $2.4–3.4 тис. за модуль, barebone-шасі $6.9–8.5 тис. ‡ оцінка до комерційних пропозицій. GPU +87% від MSRP ($8 565 у 2025); TrendForce очікує у 4К26 ще +10–15% для DRAM і +15–20% для NAND, тому ціни RAM і SSD фіксуємо в пропозиції. У колокації ДБЖ, стійку й генератор надає майданчик: рядки 7–8 зникають (−$11 тис.), але росте OPEX. Для другого вузла додаються комутатор і NIC 100 GbE.

Варіанти. B: 8 × RTX PRO 5000 72 ГБ ($9–9.6 тис., 300 Вт) дає ≈ **$140 тис.** і ≈ 59% обчислень Max-Q (72 ГБ вимагають fp8). C: 4 + 4 GPU, ≈ **$130 тис.** зараз і $64 тис. згодом, коли завантаження підтвердить потребу. Те саме шасі, ті самі воркери.

1.2 Чому саме так

Компонент	Вибір	Обґрунтування
GPU	RTX PRO 6000 Blackwell **Max-Q**	96 ГБ тримають обидва експерти Wan 2.2 A14B у bf16 (≈ 64 ГБ) без offload. Blackwell дає FP8 і NVFP4 (у Hopper FP4 немає), є ECC, драйвер не під обмеженнями GeForce. Max-Q: 300 Вт і 87% BF16 від 600-ватної версії (439 проти 504 TFLOPS), є в списку підтримки шасі, 8 × 300 Вт лишають БЖ у режимі 3+1. На Wan 2.2 швидша за H100 PCIe/NVL: 734 с (600 Вт; для Max-Q закладаємо +10–20%) проти 1059–1071 с
VRAM	8 × 96 = 768 ГБ	Wan 2.2 A14B у bf16: 2 експерти × 28 ГБ + umT5 ≈ 11 ГБ + VAE й активації 720p вміщаються у 96 ГБ без offload; на 72 ГБ потрібен fp8 (≈ 35 ГБ). На 24–32 ГБ fp8 і offload: RTX 5090 дає 1297 с проти 734 с
CPU	2 × EPYC 9355	8 слотів x16 підключено до CPU напряму, без PCIe-свічів. 32 ядра на сокет вистачає на 8 воркерів, FFmpeg, PostgreSQL і vLLM. Дешевший за Xeon 6737P на 34% ($3 694 проти $5 594). На Xeon повідомляли про низьку P2P-швидкість між RTX PRO 6000 (Level1Techs)
PCIe	Gen5 ×16 на кожен GPU	64 ГБ/с у кожен бік. P2P працює: ≈ 53–56 ГБ/с у сокеті, 39–51 між сокетами (виміри спільноти, rtx6kpro). NVLink немає, тому дизайн не залежить від міжGPU-трафіку. Перевірка: `nvidia-smi topo -m`, nccl-tests, `iommu=pt`

Компонент	Вибір	Обґрунтування
RAM	512 ГБ (8 × 64 ГБ)	Page cache моделей ≈ 100–150 ГБ, 8 процесів по ≈ 8 ГБ, vLLM, PostgreSQL. 4 канали з 12 на сокет (≈ 190 ГБ/с): модель обмежує NVMe (≈ 14 ГБ/с), не RAM. 16 слотів вільні (до 1.5 ТБ), донаселимо, коли ціни впадуть ($2.4–3.4 тис. за 64 ГБ)
Диски	4 × 3.84 ТБ NVMe RAID10, ОС на 2 × SATA RAID1	7.7 ТБ: моделі ≈ 2 ТБ, результати за 90 днів ≈ 1.5 ТБ, scratch ≈ 1 ТБ. 1 DWPD із запасом (запис ≈ 100–300 ГБ/добу). Модель на 64 ГБ вантажиться за ≈ 5–10 с. Щоночі бекап restic у S3 або NAS
Живлення	4 × 2000 Вт Titanium, 230 В	GPU 2.4 кВт + CPU 0.56 + вентилятори ≈ 0.25 + решта ≈ 0.3 = ≈ **3.6 кВт**, пік до 4.2 кВт (оцінка, замір при burn-in). Режим 2+2 дає 4 кВт на ввід (A/B), тому ліміт GPU 270 Вт (≈ −5% швидкості) тримає пік < 4 кВт; 3+1 (до 6 кВт) запасний, без резерву вводу. Вводи A/B від незалежних ДБЖ або ліній майданчика; ДБЖ на 5–10 хв для вимкнення через NUT, далі генератор
Охолодження	Повітря спереду назад, 18–27 °C на вході	≈ 3.6 кВт тепла ≈ 12 тис. BTU/год. Шасі працює до 35 °C, але тротлінг GPU починається раніше. Вентилятори шумні: серверна кімната або колокація, не офіс

1.3 Відхилені варіанти

Варіант	Чому ні
8 × RTX 5090 (32 ГБ)	Ліцензія GeForce забороняє datacenter deployment (§ 2.8) і commercial hosting (§ 2.7). 32 ГБ означає offload (1297 с проти 734 с). Немає ECC і офіційного P2P. Близько $5 тис. за карту ($156/ГБ проти $167/ГБ): за ціною різниця мала, вирішують ліцензія й ECC
RTX PRO 6000 Server Edition, 600 Вт	Немає в списку підтримки AS-4125GS-TNRT. 8 × 600 Вт = 4.8 кВт лише на GPU, близько до межі 6 кВт. Відомо про випадок, коли в шасі Supermicro потужність GPU обмежували до 450 Вт. +15% BF16 не варті ризику
H100 / H200 NVL	Повільніші на Wan 2.2 (PCIe 1059 с, NVL 1071 с проти 734 с) і дорожчі. HBM і NVLink не потрібні для job-per-GPU. Hopper без FP4: NVFP4-моделі для Blackwell на ньому не працюють
10 GPU в одному корпусі	У шасі 8 double-width слотів. Більше GPU означає інший корпус і більший домен збою, тому краще другий вузол (див. 1.4)



Рис. 1. Топологія вузла: GPU підключені напряму до CPU. Джерело: сторінка шасі Supermicro AS-4125GS-TNRT.

1.4 Multi-GPU і масштабування

Основний режим: одне завдання на один GPU. Масштабування лінійне, збій одного GPU (XID) не зупиняє інших семи, NVLink не потрібен. Інші режими вмикаються за потреби:

Режим	Як працює	Коли	Ефект
Job-per-GPU	ComfyUI-воркер на GPU, чергу розбирає диспетчер	95% завдань	≈ 20–30 кліпів/год на GPU (4-step)
Sequence parallel (Ulysses/USP, xDiT)	Кліп ділиться на 4 GPU одного сокета	«Hero»-рендер: 720p без дистиляції, далі апскейл до 1080p	Офіційно на H100: 3.6× на 4 GPU, 6.7× на 8. На PCIe очікуємо на 10–35% менше (оцінка)
Пули GPU	hq × 5 (Wan 2.2), fast × 1 (LTX-2.5), media × 1 (зображення, звук), llm × 1	Завжди	Диспетчер переносить GPU між пулами за глибиною черги (крім GPU7 з MIG)
MIG	GPU7 → 2 × 48 ГБ для vLLM (Qwen3) і допоміжних сервісів	Малі сервіси	Ізоляція. Для відео не годиться: слайс 48 ГБ дає 1613 с проти 734 с

Топологія. Воркер прив'язується до сокета свого GPU (`numactl`), multi-GPU завдання плануються в межах сокета, топологію й P2P перевіряємо при прийманні. **Масштабування.** Шасі вміщує максимум 8 GPU, тому далі масштабуємося вузлами: другий сервер реєструє свої GPU в тому самому PostgreSQL, диспетчер видає завдання на обидва. PostgreSQL і сховище виносяться з вузла (Patroni, кластер SeaweedFS), для другого вузла додаються комутатор і NIC 100 GbE. Kubernetes (K3s, GPU Operator, Kueue) має сенс від трьох вузлів.

2. AI-стек і розгортання

2.1 Моделі

Призначення	Модель	Чому	VRAM	Ліцензія
Текст і зображення у відео	**Wan 2.2 A14B** + 4-step LoRA (LightX2V), TI2V-5B для чернеток	Найкраща відкрита модель із чистою ліцензією: Wan 2.5–3.0 лише через API. Є LoRA, ComfyUI, дистиляція. 720p, 81 кадр	≈ 64 ГБ bf16, ≈ 35 ГБ fp8	Apache-2.0
Відео зі звуком, до 4K	**LTX-2.5** (22B)	Найкраща відкрита модель без територіальних обмежень. Дистильована LTX-2.3: кліп 768×512 за 7.5 с на RTX PRO 6000 (Runpod)	≈ 32 ГБ	Безкоштовно до $10 млн виручки групи
Персонажі, мовлення	Wan2.2-Animate-2-14B, Wan2.2-S2V-14B	Перенесення руху й lip-sync без окремого стеку	20–64 ГБ	Apache-2.0
Кадри, пакшоти	Qwen-Image-Edit-2511, Z-Image-Turbo, FLUX.2 klein 4B	FLUX.2 dev і klein 9B некомерційні: заблоковані	13–40 ГБ	Apache-2.0
Фініш	SeedVR2 (апскейл), RIFE (ліцензію перевірити), FFmpeg з NVENC	480p плюс апскейл дешевший за нативний 1080p	від 8 ГБ	SeedVR2: Apache-2.0, FFmpeg: LGPL
Мова, промпти	Qwen3-30B-A3B (vLLM, fp8 ≈ 31 ГБ), Qwen3Guard, Whisper large-v3 (WER uk 6.5% на FLEURS), robinhad/ukrainian-tts	Переклад UA→EN, розкадровка, фільтр промптів, субтитри, озвучка	слайс 48 ГБ	Apache-2.0, MIT
Лише тест	MiniMax H3, HunyuanVideo 1.5, MAGI-2	H3 і Hunyuan виключають ЄС і Британію (H3 ще США й Корею), MAGI-2 хоче 8 Hopper		Не для клієнтів ЄС/США

У production потрапляє лише модель із реєстру ліцензій (прапорець у БД): Apache/MIT, а LTX-2.5 за умовами ліцензії з щорічною перевіркою виручки групи.

2.2 Системний стек

Шар	Вибір	Примітка
ОС	Ubuntu Server 24.04.4 LTS, ядро 6.17 (HWE)	У QA-таблиці NVIDIA. 26.04.1 вийшла 27.08.2026, але для x86 її там ще немає
Драйвер	NVIDIA **R580 LTSB**, open kernel modules, підтримка до 06.2028	Open-модулі обов'язкові для Blackwell. R595 запасний, R615 (new-feature) не для production. `nvidia-persistenced`, ECC вмикаємо явно
CUDA	13.0 у контейнерах, на хості лише драйвер	У CUDA 13.4 відомий баг cuBLASLt grouped GEMM на Blackwell
PyTorch	2.14.x, колеса cu130, Python 3.12	cu126 без kernels для Blackwell. 2.15 вийде 28.10, беремо після двох тижнів тестів
Контейнери	Docker Engine 29.8 + NVIDIA Container Toolkit 1.20 (CDI)	Образи на `nvidia/cuda`. FlashAttention і SageAttention збираємо самі: офіційних колес для sm_120 немає
Рушії	ComfyUI (GPL-3.0, headless API, пін комітів), LightX2V, vLLM, Diffusers	Кожному воркеру свій GPU (`device_ids`) і своя модель
Дані, доступ	PostgreSQL, SeaweedFS (S3), Caddy, Keycloak, WireGuard	MinIO заархівовано в квітні 2026, тому не беремо. ComfyUI лише за SSO

2.3 Платформа: вебінтерфейс, API, черга

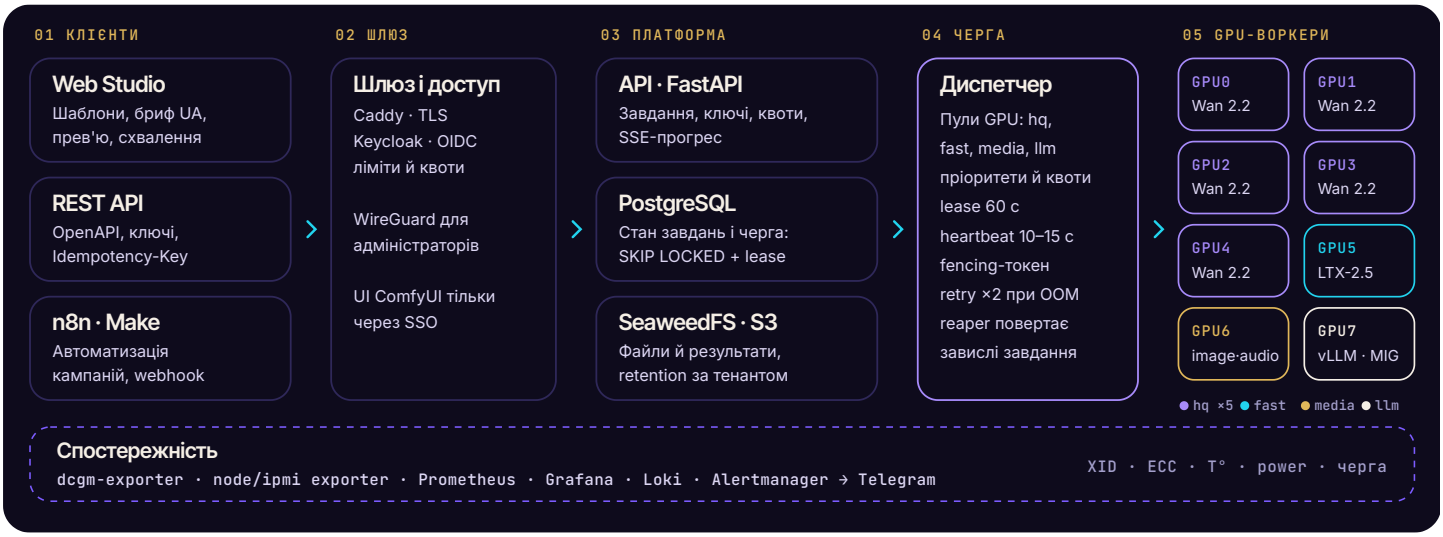


Рис. 2. Платформа: клієнти → шлюз → API → черга в PostgreSQL → воркер на кожен GPU. Моніторинг збирає метрики з усіх рівнів.

Web Studio (Next.js): шаблони кампаній (рілс 9:16, сторіс, банер 1:1, ролик 16:9), бриф українською, перегляд, схвалення, версії. Бренд-кіт накладається детерміновано через FFmpeg, а не моделлю: текст і логотипи модель спотворює. Ролі: адмін, креатор, глядач; квоти — на команду. ComfyUI бачать лише технічні користувачі через SSO.

API (FastAPI, OpenAPI 3.1): `POST /v1/jobs` з `Idempotency-Key` повертає `202`; `GET /v1/jobs/{id}` віддає статус, прогрес, результати, таймінги; `DELETE` скасовує; SSE для прогресу; webhook з HMAC-підписом і повторами; API-ключі зі scope й квотами. n8n або Make підключаються через webhook.

```
POST /v1/jobs     Idempotency-Key: 7c9e…
{ "workflow": "wan22_i2v_lightning@3", "priority": "batch",
  "inputs": { "prompt_uk": "Кава на світанку", "image": "s3://assets/product.png", "duration_s": 5, "aspect": "9:16" },
  "webhook": { "url": "https://crm.example/hook", "events": ["succeeded", "failed"] } }
→ 202 { "id": "job_01J…", "status": "queued", "queue_position": 3 }
```

Черга (`deploy/queue`: SQL і 9 тестів на PostgreSQL 16). PostgreSQL — це і стан, і черга (`SELECT … FOR UPDATE SKIP LOCKED` за пулом і пріоритетом). Агент на GPU бере завдання й запускає ComfyUI через локальний API. Кожні 10–15 с він продовжує lease (60 с) heartbeat-ом, орієнтуючись на прогрес із `/ws`.

- **Fencing-токен:** завершити завдання може лише власник актуального lease. Це закриває «зомбі-воркера», який нібито зник, але дописує результат (відомий випадок у Procrastinate, issue #1633).
- **Reaper** повертає завдання з простроченим lease. Для OOM і збою вузла — 2 повтори з деградацією параметрів (fp8, VAE tiling) або в іншому пулі, для помилок валідації — жодного. Жорсткий timeout на пул, окремий `start_deadline`.
- **Idempotency:** унікальна пара (tenant, ключ), повторний POST повертає те саме завдання. Той самий підхід (outbox, повтори з backoff, circuit breaker) реалізовано в techcom-ai-ops.
- **Чому не Celery/Redis:** завдання довше за `visibility_timeout` виконується вдруге. У RabbitMQ типове значення `consumer_timeout` — 30 хв, а це верхня межа тривалості наших завдань. Temporal потім, для багатокрокових конвеєрів.

Рис. 3. Конвеєр завдання: бриф → промпт і розкадровка (Qwen3) → ключовий кадр (Qwen-Image) → відео (Wan 2.2) → апскейл, озвучка, бренд-оверлей → маркування (VideoSeal, C2PA) → webhook. Кожен крок іде в чергу окремо, зі своїм пулом GPU.

Маркування і право. AI Act, ст. 50 діє з 02.08.2026, а добровільний Code of Practice (10.06.2026) описує два шари: підписані метадані (C2PA, c2pa-rs) і невидимий водяний знак (VideoSeal, MIT). В Україні результат без творчої участі людини захищає право sui generis на 25 років (Закон № 2811-IX), а зображення чи голос людини потребують письмової згоди (ст. 8 Закону про рекламу, ст. 307–308 ЦК). Тому в UI є поле consent ID, а журнал зберігає prompt, seed, модель, оператора й хеш.

2.4 Оптимізація інференсу

Базова лінія на RTX PRO 6000 600 Вт (ComfyUI, Wan 2.2, 1280×704, 81 кадр, 20 кроків): **734 с** у fp16, **656 с** у fp8; для Max-Q закладаємо +10–20%. Далі за впливом:

1. **Дистиляція кроків.** 4-step LoRA без CFG: 4 проходи DiT замість 40, до 10× (HunyuanVideo 1.5: ≈ 25× за даними LightX2V). Генерація кліпу скорочується з ≈ 12 до ≈ 2 хв.
2. **Квантизація Blackwell.** FP8 дає ≈ 1.5–2× на лінійних шарах. NVFP4-Sparse варіант Wan 2.2: понад 50× end-to-end проти 40 кроків на RTX 5090 (дані LightX2V, перевіряємо на Max-Q у пілоті).
3. **Увага.** На 720p це 72% FLOPs, тому SageAttention 2/3 і розріджена увага важливіші за NVFP4 на лінійних шарах.
4. **Резидентні моделі.** Завдання йде на GPU, де модель уже у VRAM. `torch.compile` з CUDA graphs, VAE tiling, кеш текстових ембедингів, 480p + SeedVR2 замість нативного 1080p, NVENC для кодування.

3. План запуску

3.1 Етапи

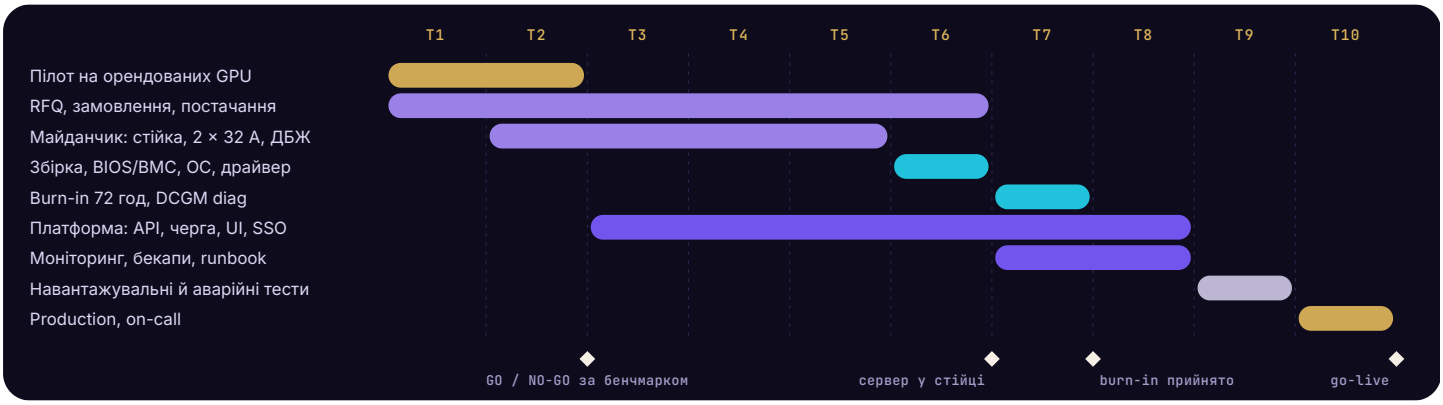


Рис. 4. План на 10 тижнів. Постачання GPU йде паралельно з розробкою платформи.

Етап	Що робимо	Критерій виходу
T1–2. Пілот	8 × RTX PRO 6000 в оренді на 72 год (≈ $1–1.6 тис.), далі 1–2 GPU на час розробки (≈ $2 тис.): бенчмарк Wan 2.2 (fp8, 4-step, NVFP4, ліміт 300 Вт) і LTX-2.5, перевірка ліцензій	≥ 20 кліпів/год на GPU, пік VRAM < 90 ГБ, GO/NO-GO
T1–6. Закупівля	RFQ у трьох дистриб'юторів з T1, замовлення в T3 після GO, письмова дата постачання GPU, фіксація цін RAM і SSD. Майданчик: стійка, 2 × 32 A, ДБЖ, генератор	Залізо на майданчику до кінця T5
T6. Збірка	оновлення BIOS/BMC, плата rev. 2.x з підтримкою EPYC 9005, налаштування BIOS (Above-4G, Resizable BAR, IOMMU, NPS1), Ubuntu autoinstall + Ansible, драйвер, Docker	Усі 8 GPU видно, `nvidia-smi topo -m` збігається з Рис. 1
T7. Burn-in 72 год	`dcgmi diag -r 4`, gpu-burn, nccl-tests, nvbandwidth, memtest86+, fio, перевірка детермінізму	0 XID, 0 ECC DBE, T < 80 °C за 25 °C на вході, без тротлінгу
T3–8. Платформа	API, черга, UI, SSO, воркери, моніторинг, бекапи, runbook. Розробка на орендованому GPU	Золоте завдання проходить наскрізь
T9. Тести відмов	1000 завдань (k6), kill воркера й ComfyUI, вимкнення БЖ і мережі, імітація відключення живлення	Жодного втраченого й жодного подвоєного завдання
T10. Production	SLO, on-call, DR: після програмних збоїв відновлення з Ansible й бекапу за < 4 год, після апаратних failover черги на орендовані GPU. Спочатку 3–5 користувачів	go-live

10 тижнів реальні, якщо GPU є на складі. Інакше (у березні 2026 постачання сягало 3–7 місяців) пілот на оренді триває, а GPU купуємо 4 + 4.

3.2 Моніторинг і стабільність

Рівень	Що міряємо	Алерт
GPU (dcgm-exporter)	`GPU_UTIL`, `FB_USED`, `GPU_TEMP`, `MEMORY_TEMP`, `POWER_USAGE`, `XID_ERRORS`, `PCIE_REPLAY_COUNTER`, `ROW_REMAP_FAILURE`. ECC і `*_VIOLATION` у стандартному наборі вимкнені, вмикаємо власним counters.csv	XID 48, 62, 64, 79, 95, 119, 120, 154: page і карантин GPU. ECC DBE > 0. Температура > 85 °C 5 хв. Replay > 100 за 15 хв. Менше 8 GPU в метриках
Хост	node_exporter, ipmi_exporter (вентилятори, БЖ, вхідна температура), smartctl, mdadm	Втрата резервування БЖ, RAID degraded, знос NVMe > 80%, диск > 80%
Живлення	NUT (ДБЖ)	Робота від батареї: черга припиняє видачу, вимкнення через 5 хв
Платформа	Очікування в черзі (p95), час виконання за workflow, частка помилок, OOM, GPU-секунди і вартість на кліп	p95 очікування > 10 хв, помилок > 5% за 15 хв, GPU без heartbeat 60 с
Продуктивність	Щотижневе «золоте» завдання з фіксованим seed	Відхилення часу > 10% від базового (деградація або тротлінг)

Конфіги: `deploy/monitoring` (compose, лічильники, 12 правил, unit-тести promtool). Логи в Loki, алерти в Telegram і e-mail. ECC перевіряється при старті, `dcgmi diag -r 2` щотижня, `-r 3` щокварталу; драйвер і образи оновлюємо спершу на одному GPU.

3.3 Ризики

Ризик	Усунення
Ціни й строки GPU, RAM, SSD: GPU +87% від MSRP, DRAM і NAND дорожчають, строки 3–7 місяців	Пілот на оренді, RFQ із фіксацією цін, варіанти 4 + 4 і RTX PRO 5000
Відключення електроенергії	Колокація з генератором, ДБЖ 10 кВА + NUT. Lease, fencing й ідемпотентність черги: після відновлення без втрат і дублів
Сумісність Blackwell (sm_120): драйвер, CUDA, PyTorch, kernels уваги	Зафіксовані образи (cu130), smoke-тест на кожен образ, fallback на SDPA, власні збірки SageAttention
Стабільність PCIe: повідомлення про XID 79 і DPC на Blackwell, одна згадка тихого пошкодження обчислень (форум NVIDIA, 08.2026)	Шасі зі списку підтримки, свіжі BIOS/VBIOS, ECC увімкнено, burn-in з перевіркою детермінізму, моніторинг XID і replay
P2P і топологія	Multi-GPU лише в межах сокета, `iommu=pt`, nccl-tests при прийманні, `NCCL_P2P_DISABLE=1` як запасний варіант
Безпека: custom nodes ComfyUI виконують довільний код, у моделях може бути pickle	Allowlist і пін комітів, лише safetensors, контейнери без інтернету, ComfyUI тільки за SSO, скан образів (Trivy)
Ліцензії й право: H3, Hunyuan, FLUX dev, LTX-2.5 понад $10 млн	Реєстр ліцензій у БД, Apache/MIT у production, C2PA + водяний знак, consent ID, модерація промптів
Єдиний вузол, низьке завантаження	Програмні збої: відновлення з Ansible й бекапів за < 4 год. Апаратні: failover черги на орендовані GPU, БД і S3 реплікуються поза вузлом. KPI завантаження, перегляд через 3 місяці, закупівля 4 + 4

3.4 Окупність

OPEX ≈ **$1.6 тис./міс.**: електрика ≈ $0.7 тис. (3.6 кВт × 730 год × PUE 1.4 × $0.20/кВт·год), колокація й канал ≈ $0.8 тис., бекапи ≈ $0.1 тис. Персонал (≈ 0.3 FTE) окремо. Колокацію й тариф уточнюємо в пропозиціях (у лютому 2026 «на добу наперед»: 8.95 грн/кВт·год).

Сценарій	$ за кліп 720p × 5 с	Примітка
Власний сервер, 100% завантаження	≈ 0.05	≈ $1.2 за GPU-год (амортизація 36 міс. + OPEX), 25 кліпів/год на GPU
Власний сервер, 30%	≈ 0.16	Простій оплачуємо самі
Оренда 8 × RTX PRO 6000 ($1.64–2.49/год за GPU)	≈ 0.07–0.10	Платимо лише за роботу
Hosted API (Veo 3.1 Lite … Veo 3.1 зі звуком, Kling 3.0)	≈ 0.25–3.75	Вищий клас якості, але дані покидають периметр

Нижче порогу 50–70% власний сервер виправдовує лише вимога тримати дані й LoRA бренду всередині. Звідси порядок: пілот на оренді, потім 4 + 4 GPU.

Досвід і референси

Власні роботи (публічні репозиторії bogdan734):

Проєкт	Що показує
Kalorad	Власна LLM з нуля на MareNostrum 5 (EuroHPC, 10 000 годин H100). Стек навчання: Slurm, FSDP, Muon, FP8, `torch.compile`
cv-video-analytics	Відеоконвеєр на YOLO11 і ByteTrack: детекція, трекінг, події, 58 тестів, CI
eva-ai-recruiter	Голосовий AI-рекрутер у production (300+ дзвінків), Docker Compose з шести сервісів, FastAPI, PostgreSQL
dzencode-comments	Docker Compose, Celery + RabbitMQ (3 черги), Redis, Prometheus `/metrics`, Locust, `docs/ARCHITECTURE.md`
techcom-ai-ops	Idempotent outbox, повтори, circuit breaker, 218 тестів: той самий шаблон надійності, що в черзі з 2.3

Відкриті реалізації, на які спирається дизайн (посилання перевірено 26.10.2026): Wan2.2 (модель, multi-GPU, таблиця швидкості) · ComfyUI · LightX2V · xDiT · LTX-2 · ComfyUI-Distributed · procrastinate · dcgm-exporter · nccl-tests · gpu-burn · c2pa-rs · VideoSeal.

Джерела

Supermicro AS-4125GS-TNRT · NVIDIA RTX Blackwell PRO · Wan2.2: Computational Efficiency · Runpod: бенчмарки · Artificial Analysis · ціна RTX PRO 6000 · TrendForce 4K26 · GeForce License · драйвери й CUDA · EU Code of Practice · Закон № 2811-IX · ліцензії моделей: картки на Hugging Face.